

QUANTA

Rapport d'Analyse Statistique

Fichier analysé

region_likert.csv

Date de génération

23/07/2026 22:42 UTC

QUANTA v0.1.0 · Python 3.12.0 · scipy 1.17.1 · statsmodels 0.14.6

SHA256 : 9e815aa2dbeea7b5202de87d5456d33b37605773a49aefebcd9bfcd080474675

SCORE DE CONFIANCE

95 / 100 — Élevé

Le score reflète les propriétés statistiques mesurables. Il n'évalue pas la qualité du design d'étude ni la validité externe.

1. Présentation des données

Nombre d'observations	200
Nombre de variables	5
Type de dataset	Dataset transversal standard

Aucun doublon détecté.

Variables

Tableau 1. Variables du dataset

Variable	Type
age	Numérique
income	Numérique
code_region	Catégorielle
satisfaction	Catégorielle

Aucune valeur manquante détectée.

1.5 Statistiques descriptives

Tableau 2. Statistiques descriptives des variables numériques

Variable	Moyenne	Médiane	Écart-type	Min	Max	Skewness	Kurtosis	% manquant
age	43.385	44	10.1381	25	59	-0.1095	-1.1737	0
income	55117.4	55484.2	13661.5	21955.1	94616.9	-0.0067	-0.1436	0

Variable catégorielle — code_region

Mode	2
% manquant	0

Tableau 3. Distribution de code_region

Modalité	Fréquence	Pourcentage
2	49	24.5
3	44	22
1	38	19

Modalité	Fréquence	Pourcentage
5	36	18
4	33	16.5

Variable catégorielle — satisfaction

Mode	4
% manquant	0

Tableau 4. Distribution de satisfaction

Modalité	Fréquence	Pourcentage
4	49	24.5
1	44	22
3	39	19.5
5	37	18.5
2	31	15.5

2. Analyse statistique

Tableau 5. Récapitulatif des analyses statistiques — mode autonome

Mode autonome : QUANTA a sélectionné et exécuté plusieurs analyses à partir de la structure du dataset.

#	Test	Variables	Statistique	p	Décision ($\alpha = 0,05$)
1	Kruskal-Wallis (non-paramétrique)	age / code_region	3.9582	0.412	Non-rejet de H_0 au seuil $\alpha = 0,05$.
2	ANOVA à un facteur (variances égales)	income / code_region	0.7804	0.539	Non-rejet de H_0 au seuil $\alpha = 0,05$.
3	Analyse de corrélation	age / income	-0.0954	0.179	Non-rejet de H_0 au seuil $\alpha = 0,05$.
4	Chi-deux d'indépendance	code_region / satisfaction	15.1427	0.514	Non-rejet de H_0 au seuil $\alpha = 0,05$.

1. Kruskal-Wallis (non-paramétrique)

Justification de la sélection

Comparaison de 'age' entre 5 groupes de 'code_region' -- normalité rejetée, Levene $p=0.6945$ -> Kruskal-Wallis (non-paramétrique). Post-hoc : non applicable (Kruskal-Wallis non significatif).

HYPOTHÈSES

H_0 : La distribution de age est identique dans les 5 groupes de code_region.

H_1 : Au moins un groupe diffère des autres.

Statistique de test	3.9582
p-value	0.412
Degrés de liberté	4

Décision statistique : Non-rejet de H_0 au seuil $\alpha = 0,05$.


Tableau 6. Résultats du Kruskal-Wallis (non-paramétrique) — age selon code_region

Mesure	Valeur
Test	Kruskal-Wallis (non-paramétrique)
Statistique	3.9582
ddl	4
p	0.412


Mesure	Valeur
ϵ^2	0.0199
Interprétation	<i>effet petit selon Cohen (1988)</i>
Puissance (1- β)	0.317 (<i>insuffisante – risque élevé d'erreur de type II</i>)

Graphiques


Distributions des variables numériques — region_likert.csv




Répartition des variables catégorielles — region_likert.csv



Tests de normalité (QQ-Plots) — region_likert.csv



Matrice de corrélation — region_likert.csv



Note : la matrice de corrélation est plus informative avec 4 variables numériques ou plus.

2. ANOVA à un facteur (variances égales)

Justification de la sélection

Comparaison de 'income' entre 5 groupes de 'code_region' -- normalité confirmée, Levene $p=0.2725$ -> ANOVA à un facteur (variances égales). Post-hoc : non applicable (ANOVA non significative).

HYPOTHÈSES

H₀ : La distribution de income est identique dans les 5 groupes de code_region.

H₁ : Au moins un groupe diffère des autres.

Statistique de test	0.7804
p-value	0.539
Degrés de liberté	4, 195

Décision statistique : Non-rejet de H₀ au seuil $\alpha = 0,05$.

Tableau 7. Résultats du ANOVA à un facteur (variances égales) — income selon code_region

Mesure	Valeur
Test	ANOVA à un facteur (variances égales)
Statistique	0.7804
ddl	4, 195
p	0.539
η^2	0.0158
Interprétation	<i>effet petit selon Cohen (1988)</i>
Puissance (1- β)	0.254 (<i>insuffisante – risque élevé d'erreur de type II</i>)

3. Analyse de corrélation

Justification de la sélection

'age' et 'income' sont toutes deux continues -> corrélation Pearson/Spearman (méthode choisie par compute.py selon la normalité conjointe).

HYPOTHÈSES

H₀ : Il n'existe pas de corrélation entre age et income ($\rho = 0$).

H₁ : Une corrélation existe ($\rho \neq 0$).

Statistique de test	-0.0954
p-value	0.179
Degrés de liberté	198

Décision statistique : Non-rejet de H₀ au seuil $\alpha = 0,05$.

Tableau 8. Résultats du spearman — age selon income

Mesure	Valeur
Test	spearman
Statistique	-0.0954
ddl	198
p	0.179

4. Chi-deux d'indépendance

Justification de la sélection

Association entre 'code_region' et 'satisfaction' -- effectif minimal attendu 5.12 -> Chi-deux d'indépendance.

HYPOTHÈSES

H₀ : code_region et satisfaction sont indépendantes.

H₁ : code_region et satisfaction sont associées.

Statistique de test	15.1427
p-value	0.514
Degrés de liberté	16

Décision statistique : Non-rejet de H₀ au seuil $\alpha = 0,05$.

Tableau 9. Résultats du Chi-deux d'indépendance — code_region selon satisfaction

Mesure	Valeur
Test	Chi-deux d'indépendance
Statistique	15.1427
ddl	16
p	0.514
V de Cramér	0.1376
Interprétation	<i>effet petit selon Cohen (1988)</i>
N	200
Puissance (1- β)	0.166 (<i>insuffisante – risque élevé d'erreur de type II</i>)

3. Interprétation

Niveau technique

Le test de corrélation de Spearman entre l'âge et le revenu a donné un coefficient de corrélation de -0.0954 avec un p-value de 0.179, ce qui indique qu'il n'y a pas de corrélation significative entre ces deux variables. Les tests de Kruskal-Wallis et ANOVA pour comparer les groupes de région pour l'âge et le revenu n'ont pas montré de différences significatives, avec des p-values respectifs de 0.412 et 0.539. Le test du Chi-deux pour l'indépendance entre la région et la satisfaction a donné un p-value de 0.514, indiquant l'absence de relation significative.

Niveau analytique

Les résultats suggèrent qu'il n'y a pas de lien significatif entre l'âge et le revenu dans cette population. De plus, les différences de région n'influent pas de manière significative sur l'âge ou le revenu. La satisfaction ne semble pas non plus être liée à la région.

Niveau décisionnel

Ces résultats pourraient indiquer que les stratégies ciblées en fonction de l'âge ou du revenu pourraient ne pas être efficaces dans cette population. De plus, les initiatives visant à améliorer la satisfaction ne devraient peut-être pas être spécifiques à une région en particulier.

⚠ SKEPTIC ENGINE — VÉRIFICATION RECOMMANDÉE

Skeptic Engine : p-value(s) > 0,05 mais l'interprétation évoque une significativité / différence notable / corrélation forte sans nuance — conclusion potentiellement incohérente.

Résumé exécutif

L'analyse a révélé qu'il n'y a pas de corrélation significative entre l'âge et le revenu, avec un coefficient de corrélation de Spearman de -0.0954 et un p-value de 0.179. Les tests de comparaison de groupes pour l'âge et le revenu en fonction de la région n'ont pas montré de différences significatives. Le test d'indépendance entre la région et la satisfaction n'a pas non plus montré de relation significative.

4. Limites et réserves

Points de vigilance du score de confiance

- Score plafonné à 95/100 — QUANTA évalue les propriétés statistiques des données mais ne peut pas mesurer la qualité du design d'étude, les biais de collecte, ni la validité externe.

Conditions d'application

- Normalité de « age » — **non vérifiée**
Shapiro-Wilk : $W = 0.9494$, $p = < 0.001$
- Normalité de « income » — **vérifiée**
Shapiro-Wilk : $W = 0.9913$, $p = 0.272$
- Homogénéité des variances (Levene) — **vérifiée**
- Score composite « respect des conditions » (95.0/100) — **vérifiée**
- Score composite « respect des conditions » (100.0/100) — **vérifiée**
- Effectifs attendus du Chi-deux (≥ 5) — **vérifiée**

Les conditions listées ci-dessus reflètent les diagnostics automatiques produits par le pipeline compute/sélecteur. Elles ne remplacent pas un jugement statistique expert sur le plan d'analyse.

En résumé

✕ Aucune différence significative de age selon code_region (Kruskal-Wallis (non-paramétrique), $p=0.412$)

✕ Aucune différence significative de income selon code_region (ANOVA à un facteur (variances égales), $p=0.539$)

✕ Pas de corrélation significative entre age et income ($r=-0.0954$, $p=0.179$)

✕ Aucune différence significative de code_region selon satisfaction (Chi-deux d'indépendance, $p=0.514$)

Anticipation des objections méthodologiques les plus fréquentes face à ces résultats.

✘ Critique possible

“La normalité est violée pour age.”

🛡 Réponse QUANTA

Le moteur a sélectionné Kruskal-Wallis (non-paramétrique) précisément parce que la normalité de age a été rejetée (Shapiro-Wilk $p < 0.001$). Ce test ne requiert pas la normalité.

✓ Défense validée

✘ Critique possible

“L'absence de significativité pourrait être due à un manque de puissance.”

🛡 Réponse QUANTA

Avec $N=200$, la puissance calculée est 0.317 (insuffisante — risque élevé d'erreur de type II). Une puissance plus élevée nécessiterait $N=138$ observations.

⚠ À vérifier avec une analyse de puissance formelle

✘ Critique possible

“La taille d'effet est négligeable ($r = -0.0954$).”

🛡 Réponse QUANTA

Correct. Même si un test était significatif, l'effet pratique serait minimal. Les conclusions restent prudentes sur la pertinence pratique des résultats.

✓ Évaluation honnête

✘ Critique possible

“L'interprétation semble incohérente avec les p-values.”

🛡 Réponse QUANTA

Le Skeptic Engine de QUANTA a détecté cette incohérence et l'a signalée explicitement en Section 3. Les conclusions doivent être lues avec cette réserve.

✓ Incohérence documentée

Annexe A — Scripts reproductibles

Code R

```
# =====
# QUANTA – Script R généré automatiquement
# Fichier analysé : region_likert.csv
# =====

# — 0. Packages requis —————
packages <- c("tidyverse", "psych", "car", "lmtest",
             "nortest", "ggplot2", "corrplot", "stargazer")
lapply(packages, function(p) {
  if (!require(p, character.only = TRUE)) install.packages(p)
  library(p, character.only = TRUE)
})

# — 1. Chargement des données —————
df <- read.csv("region_likert.csv", sep = ",", header = TRUE,
              stringsAsFactors = FALSE, encoding = "UTF-8")
cat("Dimensions :", nrow(df), "lignes x", ncol(df), "colonnes\n")

# — 2. Aperçu structurel —————
str(df)
summary(df)

# — 3. Nettoyage —————
df <- df[!duplicated(df), ]

# Aucune valeur manquante détectée – pas d'imputation nécessaire

# — 4. Statistiques descriptives —————
describe(df[, c("age", "income")])

# — 5. Tests de normalité —————
shapiro.test(df$age) # H0 : distribution normale
shapiro.test(df$income) # H0 : distribution normale

par(mfrow = c(2, 1))
qqnorm(df$age, main = "QQ-Plot age"); qqline(df$age, col = "red")
qqnorm(df$income, main = "QQ-Plot income"); qqline(df$income, col = "red")
par(mfrow = c(1, 1))

# — 6. Matrice de corrélation —————
corr_matrix <- cor(df[, c("age", "income")],
                  use = "complete.obs", method = "spearman")
print(round(corr_matrix, 3))
corrplot(corr_matrix, method = "color", type = "lower",
         tl.col = "black", addCoef.col = "black")

# — 7. Régression OLS —————
# Non générée automatiquement : aucune variable cible pertinente
# n'a été identifiée pour ce dataset (voir audit QUANTA).

# — 8. Visualisations ggplot2 —————
ggplot(df, aes(x = age)) +
  geom_histogram(fill = "#c9a84c", color = "#0a0a0a", bins = 30) +
  geom_vline(aes(xintercept = mean(age)),
            color = "#00d4ff", linetype = "dashed") +
  theme_minimal() +
  labs(title = "Distribution – age",
       x = "age", y = "Fréquence")
```

```
cat("\n☑ Script QUANTA exécuté avec succès.\n")
```

Code Stata

```
* =====
* QUANTA – Script Stata généré automatiquement
* Fichier analysé : region_likert.csv
* =====

clear all
set more off
capture log close
log using "QUANTA_analyse.log", replace

* — 1. Chargement des données —————
import delimited "region_likert.csv", delimiter(",") varnames(1) clear
describe
summarize

* — 2. Nettoyage —————
duplicates drop
duplicates report

misstable summarize
* Aucune valeur manquante détectée – pas d'imputation nécessaire

* — 3. Statistiques descriptives —————
summarize age income, detail
tabstat age income, stats(n mean sd min p25 p50 p75 max skewness kurtosis)

* Variables catégorielles
tabulate code_region
tabulate satisfaction

* — 4. Tests de normalité —————
swilk age /* Shapiro-Wilk : H0 = distribution normale */
swilk income /* Shapiro-Wilk : H0 = distribution normale */
sktest age /* Skewness-Kurtosis test */
sktest income /* Skewness-Kurtosis test */

* — 5. Corrélations —————
pwcorr age income, sig star(0.05)
spearman age income

* — 6. Régression OLS —————
* Non générée automatiquement : aucune variable cible pertinente
* n'a été identifiée pour ce dataset (voir audit QUANTA).

* — 7. Visualisations —————
histogram age, bin(30) ///
    title("Distribution – age") ///
    xtitle("age") ytitle("Fréquence") ///
    scheme(s2color)

log close
* ☑ Script QUANTA exécuté avec succès.
```

Annexe C — Références méthodologiques

- Shapiro, S. S., & Wilk, M. B. (1965). An analysis of variance test for normality. *Biometrika*, 52(3-4), 591-611.
- Levene, H. (1960). Robust tests for equality of variances. In I. Olkin (Ed.), *Contributions to Probability and Statistics* (pp. 278-292). Stanford University Press.
- Fisher, R. A. (1925). *Statistical methods for research workers*. Oliver & Boyd.
- Kruskal, W. H., & Wallis, W. A. (1952). Use of ranks in one-criterion variance analysis. *Journal of the American Statistical Association*, 47(260), 583-621.
- Pearson, K. (1900). On the criterion that a given system of deviations from the probable in the case of a correlated system of variables is such that it can be reasonably supposed to have arisen from random sampling. *Philosophical Magazine*, 50(302), 157-175.
- Spearman, C. (1904). The proof and measurement of association between two things. *American Journal of Psychology*, 15(1), 72-101.
- Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2nd ed.). Lawrence Erlbaum Associates.

Annexe D — Script Python

Script généré automatiquement — exécutable dans Google Colab (upload du fichier requis).

```
# =====
# QUANTA - Script Python généré automatiquement
# Fichier analysé : region_likert.csv
# Exécutable dans Google Colab (gratuit)
# =====

# == 0. Installation des packages =====
!pip install pandas numpy scipy statsmodels pingouin matplotlib seaborn scikit-posthocs -q

# == 1. Chargement des données =====
import pandas as pd
import numpy as np
from scipy import stats
import matplotlib.pyplot as plt
import seaborn as sns

# Dans Colab : Runtime > Upload du fichier, ou montez Drive.
df = pd.read_csv('region_likert.csv', sep=',', encoding='utf-8')
print(f"Dimensions : {df.shape[0]} lignes, {df.shape[1]} colonnes")
print(df.head())

# == 2. Statistiques descriptives =====
numeric_cols = ['age', 'income']
print(df[numeric_cols].describe())

# == 3. Tests de normalité =====
for col in numeric_cols:
    series = df[col].dropna()
    if len(series) < 3:
        print(f"Shapiro-Wilk {col} : échantillon insuffisant")
        continue
    # Shapiro limité à n<=5000 (contrainte scipy)
    sample = series if len(series) <= 5000 else series.sample(5000, random_state=42)
    stat, p = stats.shapiro(sample)
    print(f"Shapiro-Wilk {col} : W={stat:.4f}, p={p:.3f}")

# == 4. Tests effectués =====

# --- Kruskal-Wallis (non-paramétrique) ---
sub = df[['age', 'code_region']].dropna()
levels = sorted(sub['code_region'].unique(), key=str)
groups = [sub.loc[sub['code_region'] == lvl, 'age'].to_numpy() for lvl in levels]
stat, p = stats.kruskal(*groups)
print(f"Kruskal-Wallis : H={stat:.4f}, p={p:.4f}")
print('Niveaux :', levels)
# Post-hoc Dunn (si significatif) :
# import scikit_posthocs as sp
# print(sp.posthoc_dunn(sub, val_col='age', group_col='code_region', p_adjust='bonferroni'))

# --- ANOVA à un facteur (variances égales) ---
sub = df[['income', 'code_region']].dropna()
levels = sorted(sub['code_region'].unique(), key=str)
groups = [sub.loc[sub['code_region'] == lvl, 'income'].to_numpy() for lvl in levels]
stat, p = stats.f_oneway(*groups)
print(f"ANOVA : F={stat:.4f}, p={p:.4f}")
print('Niveaux :', levels)
# Post-hoc Tukey (si significatif) :
from statsmodels.stats.multicomp import pairwise_tukeyhsd
if p < 0.05:
```

```

print(pairwise_tukeyhsd(sub['income'], sub['code_region']))

# --- spearman ---
x = df['age'].dropna()
y = df['income'].dropna()
idx = x.index.intersection(y.index)
x, y = x.loc[idx], y.loc[idx]
r, p = stats.spearmanr(x, y)
print(f"Spearman : rho={r:.4f}, p={p:.4f}")

# --- Chi-deux d'indépendance ---
table = pd.crosstab(df['code_region'], df['satisfaction'])
print(table)
chi2, p, dof, expected = stats.chi2_contingency(table)
print(f"Chi-deux : chi2={chi2:.4f}, ddl={dof}, p={p:.4f}")
print('Effectifs attendus :')
print(expected)

# == 5. Visualisations =====
plt.style.use('dark_background')
sns.set_theme(style='darkgrid', rc={
    'axes.facecolor': '#F8F9FA',
    'figure.facecolor': '#FFFFFF',
    'text.color': '#1A1A1A',
    'axes.labelcolor': '#1A1A1A',
    'xtick.color': '#555555',
    'ytick.color': '#555555',
})
plot_cols = numeric_cols[:4] # limiter pour lisibilité Colab
fig, axes = plt.subplots(len(plot_cols), 2, figsize=(10, 3 * len(plot_cols)))
if len(plot_cols) == 1:
    axes = np.array([axes])
for i, col in enumerate(plot_cols):
    series = df[col].dropna()
    axes[i, 0].hist(series, bins=20, color='#C9A84C', edgecolor='#FFFFFF')
    axes[i, 0].set_title(f'Histogramme - {col}', color='#C9A84C')
    stats.probplot(series, dist='norm', plot=axes[i, 1])
    axes[i, 1].set_title(f'QQ-Plot - {col}', color='#00D4FF')
plt.tight_layout()
plt.show()

print("\n[OK] Script QUANTA execute - comparer les p-values au rapport PDF.")

```

Annexe E — Journal d'audit

Chronologie des étapes d'analyse (horodatage UTC).

Heure	Étape	Détail
22:36:13	Chargement du fichier	200 lignes, 5 colonnes, encodage utf-8
22:36:13	Diagnostic structurel	2 variables numériques, 2 catégorielles
22:36:17	Test : Kruskal-Wallis (non-paramétrique)	action=compare_groups_multi, target=age, group=code_region, p=0.411692
22:36:21	Test : ANOVA à un facteur (variances égales)	action=compare_groups_multi, target=income, group=code_region, p=0.539131
22:36:24	Test : spearman	action=correlation, target=age, group=income, p=0.17917
22:36:28	Test : Chi-deux d'indépendance	action=association, target=code_region, group=satisfaction, p=0.514215
22:36:31	Test : descriptive_only	action=descriptive_only
22:36:35	Génération du rapport	PDF généré avec succès