

QUANTA

Rapport d'Analyse Statistique

Fichier analysé

test_identifier_bug.csv

Date de génération

03/09/2026 08:06 UTC

QUANTA v0.1.0 · Python 3.12.0 · scipy 1.17.1 · statsmodels 0.14.6
SHA256 : 9b73d26edc07213bd928233a98d10eca5f090b66dcdce9b42e563ac50fa753bb

SCORE DE CONFIANCE

95 / 100 — Élevé

Le score reflète les propriétés statistiques mesurables. Il n'évalue pas la qualité du design d'étude ni la validité externe.

1. Présentation des données

Nombre d'observations	219
Nombre de variables	5
Type de dataset	Dataset transversal standard

Aucun doublon détecté.

Variables

TABLEAU 1. VARIABLES DU DATASET

Variable	Type
SUP_HA	Numérique
Rendement	Numérique
Production	Numérique
Identifiant	Catégorielle
Region	Catégorielle
Identifiant	Identifiant (exclue de l'analyse)

Aucune valeur manquante détectée.

1.5 Statistiques descriptives

TABLEAU 2. STATISTIQUES DESCRIPTIVES DES VARIABLES NUMÉRIQUES

Variable	Moyenne	Médiane	Écart-type	Min	Max	Skewness	Kurtosis	% manquant
SUP_HA	2.8105	2.75	1.3765	0.51	4.99	-0.0507	-1.3135	0
Rendement	5.4378	5.31	2.694	1.03	9.87	0.0449	-1.301	0
Production	2610.88	2628	1169.97	554	4990	0.0342	-0.9195	0

Variable catégorielle — Identifiant

Mode	zlxh-pnpo-ctrl
% manquant	0

TABLEAU 3. DISTRIBUTION DE IDENTIFIER

Modalité	Fréquence	Pourcentage
zlxh-pnpo-ctrl	3	1.37
suno-ativ-twqv	3	1.37
mxvv-jnyp-kwvq	3	1.37
cqdt-zjth-uslm	3	1.37
kyrh-xevn-vbwl	3	1.37
chiz-bpvj-pxqc	3	1.37
aanl-afhs-zixo	3	1.37
fjzl-voxq-elbm	3	1.37
ooxl-rtrk-quib	3	1.37
mbsx-ujfc-nusa	3	1.37
jfif-tfup-ckbf	3	1.37
edsc-fksc-qgdb	3	1.37
kcyx-gtvo-tekj	3	1.37
ojmm-qchw-otbj	3	1.37
east-uqhx-mjpv	3	1.37
sqbj-iyhw-hdzt	3	1.37
vqab-uqff-lszo	3	1.37
uyqr-kihz-ljxz	3	1.37
cfcq-lgyj-bbsa	3	1.37
slmf-bieu-cmip	3	1.37
jids-vvki-npnu	3	1.37
rmjf-ipot-gejj	3	1.37
dknd-jrqb-nodh	3	1.37
bjmp-lrcp-mnbw	3	1.37
bxwf-naal-esvi	3	1.37
tucy-duvu-pbtw	3	1.37
rjvr-jehw-iouh	3	1.37
vbzm-apjq-efjm	3	1.37

Modalité	Fréquence	Pourcentage
uzep-oxhl-slzh	3	1.37
hhwp-autx-efth	3	1.37
bwdd-gfjg-hrdy	3	1.37
elpj-zeua-hcrj	3	1.37
laju-uhuo-zrcj	3	1.37
zipi-tatd-jvmt	3	1.37
qxqh-vvxx-puts	3	1.37
ivqs-srqh-ptsy	3	1.37
lqye-rmnd-jkqk	3	1.37
vfuz-yuie-bxwu	3	1.37
xrkh-eghv-nxoz	3	1.37
bruw-kaxg-tjef	3	1.37
jgrn-qaez-qejk	3	1.37
mnuz-bsqe-dcfh	3	1.37
ptuy-xycr-zupa	3	1.37
eatu-vovl-jkpz	3	1.37
dmdy-vdnb-zkhs	3	1.37
ehfw-yywj-itow	3	1.37
repc-ymig-fjkb	3	1.37
wesb-mbqh-ywct	3	1.37
jzcv-mwrf-mdwp	3	1.37
xrho-wonf-ztld	3	1.37
bofu-gbhv-bfby	3	1.37
wdun-tngg-ddlp	3	1.37
pszu-dwlc-sqki	3	1.37
wqhn-gelc-zyyk	3	1.37
mudb-ssfb-vrrw	3	1.37
xtnh-ccjv-wrdy	3	1.37

Modalité	Fréquence	Pourcentage
btuc-bclm-nhbv	3	1.37
wntp-aeel-fhgu	3	1.37
jqtv-gfre-kgrv	3	1.37
olod-rmpz-lgme	3	1.37
lstf-exsb-fkqe	3	1.37
tavf-mvve-scon	3	1.37
btyn-eqbk-gfkf	3	1.37
qqri-qhvq-lefw	3	1.37
mccj-vbmt-wufy	3	1.37
kont-rsdt-xffi	2	0.91
ubsl-etdh-fgwg	2	0.91
crbk-nzbv-uhkg	2	0.91
mhay-vlfc-pzgf	2	0.91
dife-iwnk-prpr	2	0.91
nbyh-uefs-hhtm	2	0.91
tbbw-rqyk-otfi	2	0.91
vvhc-zfhq-frno	2	0.91
vebz-ylxb-bmbg	2	0.91
twpb-wjhv-pnl	2	0.91
jqp-ph-dyai-sqnp	2	0.91
qnyi-lrqe-nycf	2	0.91

Variable catégorielle — Region

Mode	Nord
% manquant	0

TABLEAU 4. DISTRIBUTION DE REGION

Modalité	Fréquence	Pourcentage
Nord	58	26.48
	57	26.03

2. Analyse statistique

TABLEAU 5. RÉCAPITULATIF DES ANALYSES STATISTIQUES — MODE AUTONOME

Mode autonome : QUANTA a sélectionné et exécuté plusieurs analyses à partir de la structure du dataset.

#	Test	Variables	Statistique	p	Décision ($\alpha = 0,05$)
1	Kruskal-Wallis (non-paramétrique)	SUP_HA / Region	4.5189	0.211	Non-rejet de H_0 au seuil $\alpha = 0,05$.
2	Kruskal-Wallis (non-paramétrique)	Rendement / Region	1.2412	0.743	Non-rejet de H_0 au seuil $\alpha = 0,05$.
3	Kruskal-Wallis (non-paramétrique)	Production / Region	4.9684	0.174	Non-rejet de H_0 au seuil $\alpha = 0,05$.
4	Analyse de corrélation	SUP_HA / Rendement	-0.1032	0.128	Non-rejet de H_0 au seuil $\alpha = 0,05$.

1. Kruskal-Wallis (non-paramétrique)

Justification de la sélection

Comparaison de 'SUP_HA' entre 4 groupes de 'Region' -- normalité rejetée, Levene $p=0.0117$ -> Kruskal-Wallis (non-paramétrique). Post-hoc : non applicable (Kruskal-Wallis non significatif).

HYPOTHÈSES

H_0 : La distribution de SUP_HA est identique dans les 4 groupes de Region.

H_1 : Au moins un groupe diffère des autres.

Statistique de test 4.5189

p-value 0.211

Degrés de liberté 3

Décision statistique : Non-rejet de H_0 au seuil $\alpha = 0,05$.


TABLEAU 6. RÉSULTATS DU KRUSKAL-WALLIS (NON-PARAMÉTRIQUE) — SUP_HA SELON REGION

Mesure	Valeur
Test	Kruskal-Wallis (non-paramétrique)
Statistique	4.5189
ddl	3
p	0.211


Mesure	Valeur
ε^2	0.0207
Interprétation	<i>effet petit selon Cohen (1988)</i>
Puissance (1- β)	0.404 (<i>insuffisante – risque élevé d'erreur de type II</i>)

Graphiques

Distributions des variables numériques — test_identifier_bug.csv




Répartition des variables catégorielles — test_identifier_bug.csv




Tests de normalité (QQ-Plots) — test_identifier_bug.csv

QUANTA — Tests de normalité (QQ-Plots)



Matrice de corrélation — test_identifier_bug.csv

Matrice de corrélation (Spearman)



Note : la matrice de corrélation est plus informative avec 4 variables numériques ou plus.

2. Kruskal-Wallis (non-paramétrique)

Justification de la sélection

Comparaison de 'Rendement' entre 4 groupes de 'Region' -- normalité rejetée, Levene $p=0.8740$ -> Kruskal-Wallis (non-paramétrique). Post-hoc : non applicable (Kruskal-Wallis non significatif).

HYPOTHÈSES

H₀ : La distribution de Rendement est identique dans les 4 groupes de Region.

H₁ : Au moins un groupe diffère des autres.

Statistique de test	1.2412
---------------------	--------

p-value	0.743
---------	-------

Degrés de liberté	3
-------------------	---

Décision statistique : Non-rejet de H₀ au seuil $\alpha = 0,05$.

TABLEAU 7. RÉSULTATS DU KRUSKAL-WALLIS (NON-PARAMÉTRIQUE) — RENDEMENT SELON REGION

Mesure	Valeur
Test	Kruskal-Wallis (non-paramétrique)
Statistique	1.2412
ddl	3
p	0.743
ϵ^2	0.0057
Interprétation	<i>effet négligeable selon Cohen (1988)</i>
Puissance (1- β)	0.133 (<i>insuffisante – risque élevé d'erreur de type II</i>)

3. Kruskal-Wallis (non-paramétrique)

Justification de la sélection

Comparaison de 'Production' entre 4 groupes de 'Region' -- normalité rejetée, Levene $p=0.5233$ -> Kruskal-Wallis (non-paramétrique). Post-hoc : non applicable (Kruskal-Wallis non significatif).

HYPOTHÈSES

H₀ : La distribution de Production est identique dans les 4 groupes de Region.

H₁ : Au moins un groupe diffère des autres.

Statistique de test	4.9684
---------------------	--------

p-value	0.174
---------	-------

Degrés de liberté	3
-------------------	---

Décision statistique : Non-rejet de H_0 au seuil $\alpha = 0,05$.

TABLEAU 8. RÉSULTATS DU KRUSKAL-WALLIS (NON-PARAMÉTRIQUE) — PRODUCTION SELON REGION

Mesure	Valeur
Test	Kruskal-Wallis (non-paramétrique)
Statistique	4.9684
ddl	3
p	0.174
ε^2	0.0228
Interprétation	<i>effet petit selon Cohen (1988)</i>
Puissance (1- β)	0.442 (<i>insuffisante – risque élevé d'erreur de type II</i>)

4. Analyse de corrélation

Justification de la sélection

3 variables numériques détectées -> ACP automatiquement ajoutée pour explorer les structures de variance.

HYPOTHÈSES

H_0 : Il n'existe pas de corrélation entre SUP_HA et Rendement ($\rho = 0$).

H_1 : Une corrélation existe ($\rho \neq 0$).

Statistique de test	-0.1032
p-value	0.128
Degrés de liberté	217

Décision statistique : Non-rejet de H_0 au seuil $\alpha = 0,05$.

TABLEAU 9. RÉSULTATS DU SPEARMAN — SUP_HA SELON RENDEMENT

Mesure	Valeur
Test	spearman
Statistique	-0.1032
ddl	217
p	0.128

Analyse en Composantes Principales (ACP)

L'ACP explore les structures de variance entre 3 variables numériques sur 219 observations.

Note d'interprétation

L'axe 1 explique 36.59% de la variance totale. Les axes 1 et 2 ensemble expliquent 70.87%. Selon le critère de Kaiser, 2 composante(s) devraient être conservée(s) (valeur propre > 1).

Valeurs propres




TABLEAU 10. VALEURS PROPRES ET VARIANCE EXPLIQUÉE PAR DIMENSION — ACP

Dimension	% variance	% cumulé
1	36.59%	36.59%
2	34.28%	70.87%
3	29.13%	100%





TABLEAU 11. VARIABLES LES MIEUX REPRÉSENTÉES SUR LES AXES 1 ET 2 — ACP

Variable	Dimension 1	Dimension 2
Production	0.2011	0.8858
Rendement	0.6794	-0.4614
SUP_HA	-0.7718	-0.1753

Plan des individus



3. Interprétation

Niveau technique

Test de corrélation de Spearman (bilatéral) : $H_0 : \rho = 0$ (absence d'association monotone) vs $H_1 : \rho \neq 0$. Statistique observée $r = -0,1032$ sur $n = 219$ observations. Valeur $p = 0,128$. Au seuil $\alpha = 5\%$, on ne rejette pas H_0 . La force de l'association est qualifiée de négligeable. Parallèlement, l'ACP sur 3 variables quantitatives standardisées retient 2 composantes selon le critère de Kaiser (valeurs propres > 1 : 1,098 et 1,028). L'inertie expliquée est de 36,59 % (axe 1), 34,28 % (axe 2), cumulée à 70,87 % pour les deux premiers axes.

Niveau analytique

La corrélation de Spearman indique qu'il n'existe pas de lien monotone discernable entre la taille de la parcelle (SUP_HA) et le rendement : les parcelles plus grandes ne produisent pas systématiquement plus ou moins par hectare que les petites. Le coefficient négatif très faible (-0,10) suggère au plus une tendance inverse infime, non distinguable du bruit d'échantillonnage. L'ACP révèle que les trois variables (surface, rendement, production totale) partagent une structure commune résumée par deux dimensions : la première oppose probablement les exploitations de grande taille à forte production totale aux petites, tandis que la seconde sépare les rendements élevés des faibles, relativement indépendamment de la surface.

Niveau décisionnel

Pour la gestion agricole, ce résultat signifie que la surface cultivée seule ne permet pas de prédire le rendement à l'hectare. Les décisions d'optimisation du rendement ne doivent pas se fonder sur la taille des parcelles. L'ACP suggère en revanche d'examiner conjointement surface, rendement et production totale : deux profils d'exploitations émergent (grandes surfaces / production totale élevée vs petites surfaces / rendement potentiellement plus intensif). Une analyse plus fine par type de culture, pratique culturale ou zone pédoclimatique est recommandée pour identifier les vrais leviers de performance.

⚠ SKEPTIC ENGINE — VÉRIFICATION RECOMMANDÉE

Skeptic Engine : $p\text{-value(s)} > 0,05$ mais l'interprétation évoque une significativité / différence notable / corrélation forte sans nuance — conclusion potentiellement incohérente.

Résumé exécutif

L'analyse de corrélation de Spearman entre la surface cultivée (SUP_HA) et le rendement ne révèle aucune association monotone statistiquement significative ($\rho = -0,103$, $p = 0,128$). L'ACP sur les trois

variables quantitatives (SUP_HA, Rendement, Production) montre que les deux premiers axes capturent 70,9 % de l'inertie totale, suggérant une structure bidimensionnelle sous-jacente. Aucune relation linéaire ou monotone forte n'émerge entre la surface et le rendement dans cet échantillon de 219 observations.

4. Limites et réserves

Points de vigilance du score de confiance

- Score plafonné à 95/100 — QUANTA évalue les propriétés statistiques des données mais ne peut pas mesurer la qualité du design d'étude, les biais de collecte, ni la validité externe.

Conditions d'application

- Normalité de « SUP_HA » — non vérifiée
Shapiro-Wilk : $W = 0.9379$, $p = < 0.001$
- Normalité de « Rendement » — non vérifiée
Shapiro-Wilk : $W = 0.9398$, $p = < 0.001$
- Normalité de « Production » — non vérifiée
Shapiro-Wilk : $W = 0.9728$, $p = < 0.001$
- Homogénéité des variances (Levene) — non vérifiée
- Score composite « respect des conditions » (95.0/100) — vérifiée
- Homogénéité des variances (Levene) — vérifiée
- Score composite « respect des conditions » (100.0/100) — vérifiée

Les conditions listées ci-dessus reflètent les diagnostics automatiques produits par le pipeline compute/sélecteur. Elles ne remplacent pas un jugement statistique expert sur le plan d'analyse.

En résumé

- ✕ Aucune différence significative de SUP_HA selon Region (Kruskal-Wallis (non-paramétrique), $p=0.211$)
- ✕ Aucune différence significative de Rendement selon Region (Kruskal-Wallis (non-paramétrique), $p=0.743$)
- ✕ Aucune différence significative de Production selon Region (Kruskal-Wallis (non-paramétrique), $p=0.174$)
- ✕ Pas de corrélation significative entre SUP_HA et Rendement ($r=-0.1032$, $p=0.128$)

Défense Scientifique

Anticipation des objections méthodologiques les plus fréquentes face à ces résultats.

✘ Critique possible

"La normalité est violée pour SUP_HA."

♥ Réponse QUANTA

Le moteur a sélectionné Kruskal-Wallis (non-paramétrique) précisément parce que la normalité de SUP_HA a été rejetée (Shapiro-Wilk $p < 0.001$). Ce test ne requiert pas la normalité.

✓ Défense validée

✘ Critique possible

"La normalité est violée pour Rendement."

♥ Réponse QUANTA

Le moteur a sélectionné Kruskal-Wallis (non-paramétrique) précisément parce que la normalité de Rendement a été rejetée (Shapiro-Wilk $p < 0.001$). Ce test ne requiert pas la normalité.

✓ Défense validée

✘ Critique possible

"La normalité est violée pour Production."

♥ Réponse QUANTA

Le moteur a sélectionné Kruskal-Wallis (non-paramétrique) précisément parce que la normalité de Production a été rejetée (Shapiro-Wilk $p < 0.001$). Ce test ne requiert pas la normalité.

✓ Défense validée

✘ Critique possible

"L'absence de significativité pourrait être due à un manque de puissance."

♥ Réponse QUANTA

Avec $N=219$, la puissance calculée est 0.404 (insuffisante — risque élevé d'erreur de type II). Une puissance plus élevée nécessiterait $N=126$ observations.

⚠ À vérifier avec une analyse de puissance formelle

✘ Critique possible

"La taille d'effet est négligeable ($\varepsilon^2 = 0.0057$)."

♥ **Réponse QUANTA**

Correct. Même si un test était significatif, l'effet pratique serait minimal. Les conclusions restent prudentes sur la pertinence pratique des résultats.

✓ Évaluation honnête

✗ **Critique possible**

"L'interprétation semble incohérente avec les p-values."

♥ **Réponse QUANTA**

Le Skeptic Engine de QUANTA a détecté cette incohérence et l'a signalée explicitement en Section 3. Les conclusions doivent être lues avec cette réserve.

✓ Incohérence documentée

Annexe A — Scripts reproductibles

Code R

```
# =====  
# QUANTA – Script R généré automatiquement  
# Fichier analysé : test_identifier_bug.csv  
# =====  
  
# — 0. Packages requis —————  
packages <- c("tidyverse", "psych", "car", "lmtest",  
              "nortest", "ggplot2", "corrplot", "stargazer")  
lapply(packages, function(p) {  
  if (!require(p, character.only = TRUE)) install.packages(p)  
  library(p, character.only = TRUE)  
})  
  
# — 1. Chargement des données —————  
df <- read.csv("test_identifier_bug.csv", sep = ",", header = TRUE,  
              stringsAsFactors = FALSE, encoding = "UTF-8")  
cat("Dimensions :", nrow(df), "lignes x", ncol(df), "colonnes\n")  
  
# — 2. Aperçu structurel —————  
str(df)  
summary(df)  
  
# — 3. Nettoyage —————  
df <- df[!duplicated(df), ]  
  
# Aucune valeur manquante détectée – pas d'imputation nécessaire  
  
# — 4. Statistiques descriptives —————  
describe(df[, c("SUP_HA", "Rendement", "Production")])  
  
# — 5. Tests de normalité —————  
shapiro.test(df$SUP_HA) # H0 : distribution normale  
shapiro.test(df$Rendement) # H0 : distribution normale  
shapiro.test(df$Production) # H0 : distribution normale  
  
par(mfrow = c(2, 2))  
qqnorm(df$SUP_HA, main = "QQ-Plot SUP_HA"); qqline(df$SUP_HA, col = "red")  
qqnorm(df$Rendement, main = "QQ-Plot Rendement"); qqline(df$Rendement, col = "red")  
qqnorm(df$Production, main = "QQ-Plot Production"); qqline(df$Production, col = "red")  
par(mfrow = c(1, 1))  
  
# — 6. Matrice de corrélation —————  
corr_matrix <- cor(df[, c("SUP_HA", "Rendement", "Production")],  
                  use = "complete.obs", method = "spearman")  
print(round(corr_matrix, 3))  
corrplot(corr_matrix, method = "color", type = "lower",  
         tl.col = "black", addCoef.col = "black")  
  
# — 7. Régression OLS —————  
# Non générée automatiquement : aucune variable cible pertinente  
# n'a été identifiée pour ce dataset (voir audit QUANTA).  
  
# — 8. Visualisations ggplot2 —————  
ggplot(df, aes(x = SUP_HA)) +  
  geom_histogram(fill = "#c9a84c", color = "#0a0a0a", bins = 30) +  
  geom_vline(aes(xintercept = mean(SUP_HA)),  
            color = "#00d4ff", linetype = "dashed") +  
  theme_minimal() +
```

```

labs(title = "Distribution - SUP_HA",
      x = "SUP_HA", y = "Fréquence")

cat("\n☒ Script QUANTA exécuté avec succès.\n")

```

Code Stata

```

* =====
* QUANTA - Script Stata généré automatiquement
* Fichier analysé : test_identifier_bug.csv
* =====

clear all
set more off
capture log close
log using "QUANTA_analyse.log", replace

* --- 1. Chargement des données -----
import delimited "test_identifier_bug.csv", delimiter(",") varnames(1) clear
describe
summarize

* --- 2. Nettoyage -----
duplicates drop
duplicates report

misstable summarize
* Aucune valeur manquante détectée - pas d'imputation nécessaire

* --- 3. Statistiques descriptives -----
summarize SUP_HA Rendement Production, detail
tabstat SUP_HA Rendement Production, stats(n mean sd min p25 p50 p75 max skewness kurtosis)

* Variables catégorielles
tabulate Identifier
tabulate Region

* --- 4. Tests de normalité -----
swilk SUP_HA /* Shapiro-Wilk : H0 = distribution normale */
swilk Rendement /* Shapiro-Wilk : H0 = distribution normale */
swilk Production /* Shapiro-Wilk : H0 = distribution normale */
sktest SUP_HA /* Skewness-Kurtosis test */
sktest Rendement /* Skewness-Kurtosis test */
sktest Production /* Skewness-Kurtosis test */

* --- 5. Corrélations -----
pwcorr SUP_HA Rendement Production, sig star(0.05)
spearman SUP_HA Rendement Production

* --- 6. Régression OLS -----
* Non générée automatiquement : aucune variable cible pertinente
* n'a été identifiée pour ce dataset (voir audit QUANTA).

* --- 7. Visualisations -----
histogram SUP_HA, bin(30) ///
  title("Distribution - SUP_HA") ///
  xtitle("SUP_HA") ytitle("Fréquence") ///
  scheme(s2color)

log close
* ☒ Script QUANTA exécuté avec succès.

```

Annexe C — Références méthodologiques

- Shapiro, S. S., & Wilk, M. B. (1965). An analysis of variance test for normality. *Biometrika*, 52(3-4), 591-611.
- Levene, H. (1960). Robust tests for equality of variances. In I. Olkin (Ed.), *Contributions to Probability and Statistics* (pp. 278-292). Stanford University Press.
- Kruskal, W. H., & Wallis, W. A. (1952). Use of ranks in one-criterion variance analysis. *Journal of the American Statistical Association*, 47(260), 583-621.
- Spearman, C. (1904). The proof and measurement of association between two things. *American Journal of Psychology*, 15(1), 72-101.
- Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2nd ed.). Lawrence Erlbaum Associates.

Annexe D — Script Python

Script généré automatiquement — exécutable dans Google Colab (upload du fichier requis).

```
# =====
# QUANTA - Script Python généré automatiquement
# Fichier analysé : test_identifier_bug.csv
# Exécutable dans Google Colab (gratuit)
# =====

# == 0. Installation des packages =====
!pip install pandas numpy scipy statsmodels pingouin matplotlib seaborn scikit-posthocs -q

# == 1. Chargement des données =====
import pandas as pd
import numpy as np
from scipy import stats
import matplotlib.pyplot as plt
import seaborn as sns

# Dans Colab : Runtime > Upload du fichier, ou montez Drive.
df = pd.read_csv('test_identifier_bug.csv', sep=',', encoding='utf-8')
print(f"Dimensions : {df.shape[0]} lignes, {df.shape[1]} colonnes")
print(df.head())

# == 2. Statistiques descriptives =====
numeric_cols = ['SUP_HA', 'Rendement', 'Production']
print(df[numeric_cols].describe())

# == 3. Tests de normalité =====
for col in numeric_cols:
    series = df[col].dropna()
    if len(series) < 3:
        print(f"Shapiro-Wilk {col} : échantillon insuffisant")
        continue
    # Shapiro limité à n<=5000 (contrainte scipy)
    sample = series if len(series) <= 5000 else series.sample(5000, random_state=42)
    stat, p = stats.shapiro(sample)
    print(f"Shapiro-Wilk {col} : W={stat:.4f}, p={p:.3f}")

# == 4. Tests effectués =====

# --- Kruskal-Wallis (non-paramétrique) ---
sub = df[['SUP_HA', 'Region']].dropna()
levels = sorted(sub['Region'].unique(), key=str)
groups = [sub.loc[sub['Region'] == lvl, 'SUP_HA'].to_numpy() for lvl in levels]
stat, p = stats.kruskal(*groups)
print(f"Kruskal-Wallis : H={stat:.4f}, p={p:.4f}")
print('Niveaux :', levels)
# Post-hoc Dunn (si significatif) :
# import scikit_posthocs as sp
# print(sp.posthoc_dunn(sub, val_col='SUP_HA', group_col='Region', p_adjust='bonferroni'))

# --- Kruskal-Wallis (non-paramétrique) ---
sub = df[['Rendement', 'Region']].dropna()
levels = sorted(sub['Region'].unique(), key=str)
groups = [sub.loc[sub['Region'] == lvl, 'Rendement'].to_numpy() for lvl in levels]
stat, p = stats.kruskal(*groups)
print(f"Kruskal-Wallis : H={stat:.4f}, p={p:.4f}")
print('Niveaux :', levels)
# Post-hoc Dunn (si significatif) :
# import scikit_posthocs as sp
# print(sp.posthoc_dunn(sub, val_col='Rendement', group_col='Region', p_adjust='bonferroni'))
```

```

# --- Kruskal-Wallis (non-paramétrique) ---
sub = df[['Production', 'Region']].dropna()
levels = sorted(sub['Region'].unique(), key=str)
groups = [sub.loc[sub['Region'] == lvl, 'Production'].to_numpy() for lvl in levels]
stat, p = stats.kruskal(*groups)
print(f"Kruskal-Wallis : H={stat:.4f}, p={p:.4f}")
print('Niveaux :', levels)
# Post-hoc Dunn (si significatif) :
# import scikit_posthocs as sp
# print(sp.posthoc_dunn(sub, val_col='Production', group_col='Region', p_adjust='bonferroni'))

# --- spearman ---
x = df['SUP_HA'].dropna()
y = df['Rendement'].dropna()
idx = x.index.intersection(y.index)
x, y = x.loc[idx], y.loc[idx]
r, p = stats.spearmanr(x, y)
print(f"Spearman : rho={r:.4f}, p={p:.4f}")

# == 5. Visualisations =====
plt.style.use('dark_background')
sns.set_theme(style='darkgrid', rc={
    'axes.facecolor': '#13131A',
    'figure.facecolor': '#0A0A0F',
    'text.color': '#E8E8E8',
    'axes.labelcolor': '#E8E8E8',
    'xtick.color': '#9A9AA8',
    'ytick.color': '#9A9AA8',
})
plot_cols = numeric_cols[:4] # limiter pour lisibilité Colab
fig, axes = plt.subplots(len(plot_cols), 2, figsize=(10, 3 * len(plot_cols)))
if len(plot_cols) == 1:
    axes = np.array([axes])
for i, col in enumerate(plot_cols):
    series = df[col].dropna()
    axes[i, 0].hist(series, bins=20, color='#C9A84C', edgecolor='#0A0A0F')
    axes[i, 0].set_title(f'Histogramme - {col}', color='#C9A84C')
    stats.probplot(series, dist='norm', plot=axes[i, 1])
    axes[i, 1].set_title(f'QQ-Plot - {col}', color='#00D4FF')
plt.tight_layout()
plt.show()

print("\n[OK] Script QUANTA execute - comparer les p-values au rapport PDF.")

```

Annexe E — Journal d'audit

Chronologie des étapes d'analyse (horodatage UTC).

Heure	Étape	Détail
08:04:47	Chargement du fichier	219 lignes, 5 colonnes, encodage utf-8
08:04:47	Diagnostic structurel	3 variables numériques, 2 catégorielles
08:04:50	Test : Kruskal-Wallis (non-paramétrique)	action=compare_groups_multi, target=SUP_HA, group=Region, p=0.210612
08:04:53	Test : Kruskal-Wallis (non-paramétrique)	action=compare_groups_multi, target=Rendement, group=Region, p=0.74313
08:04:56	Test : Kruskal-Wallis (non-paramétrique)	action=compare_groups_multi, target=Production, group=Region, p=0.174126
08:05:02	Test : spearman	action=correlation, target=SUP_HA, group=Rendement, p=0.1277
08:05:05	Test : descriptive_only	action=descriptive_only
08:06:25	Génération du rapport	PDF généré avec succès